

1. ภาพรวมระบบ

ผู้ใช้พูดคุยกับมาสคอตผ่าน Kiosk ด้วยภาษาไทย/อังกฤษ ระบบ AI ตอบสนองพร้อมเสียงและขยับปากตามเสียงจริง โดยใช้วีดิโอคลิปที่เตรียมไว้ล่วงหน้าแทนการสร้างภาพเคลื่อนไหวแบบ real-time

2. ลำดับการทำงาน



3. โครงสร้างระบบ

แสดงผล	ควบคุม	AI และเสียง
ทำทาง — วีดิโอ 2 ชั้นสลับกันแสดง แทบไม่มีความล่าช้า ปาก — สลับคลิปรูปปากตามเสียงที่พูดออกมา (ดูข้อ 4)	กำหนดการขยับปาก — รับสัญญาณจาก Azure TTS แล้วสลับคลิปปากให้ตรงเวลา ควบคุมทำทาง — จัดการการเปลี่ยนสถานะ: รอ → ได้ยิน → กำลังพูด → รอ วิเคราะห์คำตอบ — อ่านคำตอบจาก AI แล้วเลือกทำทางที่เหมาะสม	ระบบ AI — Claude/GPT + ฐานข้อมูล MRT แปลงข้อความเป็นเสียง — Azure TTS เสียงไทย/อังกฤษ พร้อมสัญญาณรูปปาก 22 แบบ รับเสียงผู้ใช้ — ผ่าน browser (Plan A) / Whisper API (Plan B)

4. วีดิโอคลิปของมาสคอต

คลิปทำทาง	คลิปรูปปาก (ฝังในคลิปล่วงหน้า)
LOOP Idle — ยืนพัก กะพริบตา LOOP Talking — ตัวยกขณะออกเสียง LOOP Thinking — เกาหัว/มองขึ้น ขณะ AI ประมวลผล ONE Greeting — โบกมือต้อนรับ ONE Pointing — ชี้ทิศทาง/แผนที่ ONE Happy — พยักหน้า ยิ้ม ONE Sorry — ส่ายหัว ยกมือ ONE Goodbye — โบกมือลา	Azure TTS บอกได้ว่าแต่ละช่วงเวลาปากอยู่ท่าไหน — เจนคลิปแยก 4 ท่าปาก ฝังเข้าไปในคลิปตั้งแต่ต้น ให้ตัวขยับและปากอยู่ในวิดีโอเดียวกัน M mouth-open — เสียง อา โอ M mouth-mid — เสียง เอ อี M mouth-small — เสียง อุ M mouth-closed — เสียง ม พ บ หรือเจียบ สลับคลิปตามสัญญาณจาก Azure — ตัวมาสคอตขยับได้ปกติเพราะปากฝังอยู่ในคลิปแล้ว

ทำไมถึงฝังรูปปากในคลิปแทนการวาดทับหน้าจอ?

❌ วาดปากทับหน้าจอ (ไม่เลือกใช้)

- วาดปากทับที่ตำแหน่งตายตัวบนหน้าจอ
- ถ้าตัวมาสคอตขยับ → ปากลอยออกจากหน้า
- ต้องคำนวณตำแหน่งปากทุก frame — ซับซ้อนมาก
- อาจมีความล่าช้าระหว่างตัวและปาก

✅ ฝังรูปปากในคลิปตั้งแต่ต้น (เลือกใช้)

- รูปปากอยู่ในวิดีโอแล้ว ไม่ต้องคำนวณเพิ่ม
- ตัวขยับได้อิสระ ปากติดหน้าเสมอ
- สลับระหว่าง 4-6 คลิปตามสัญญาณเสียง
- ผลลัพธ์ไหลลื่นกว่า ไม่มีความล่าช้า

⚠️ เสียงภาษาไทยบางเสียงอาจไม่ตรงกับรูปปากที่ Azure กำหนดไว้ 100% ความแม่นยำต้องทดสอบก่อนนำไปใช้จริง

5. Technology Stack

Azure Cognitive Services TTS

Claude API / GPT-4o

Web Speech API / Whisper

HTML5 Video (Double Buffer)

6. ค่าใช้จ่าย API และข้อจำกัด

Azure TTS — Text-to-Speech (เสียงมาสดสด)

✓ Free Tier (F0)

- 500,000 ตัวอักษร/เดือน ฟรี
- ~ มาสดสดพูดได้ประมาณ 3,000–5,000 ประโยค/เดือน
- งานนิทรรศการไม่กี่วัน — น่าจะไม่เกิน free tier
- 1 Azure account สร้าง free Speech resource ได้ 1 ตัว

⚡ เมื่อเกิน Free Tier (S0)

- คิดเงินเฉพาะ ส่วนที่เกิน — ระบบไม่หยุดทำงาน
- อัตรา \$16 / 1,000,000 ตัวอักษร (~540 บาท)
- ใช้งาน production รายเดือน ~ 500–2,000 บาท/เดือน

📍 เลือก Region: **Southeast Asia (Singapore)** — ใกล้ไทยที่สุด เสียงออกเร็วกว่าเลือก US หรือ Europe

LLM API — ระบบ AI ตอบคำถาม

Plan A — งานนิทรรศการ

traffic น้อย ประมาณการค่า LLM ไม่เกิน 500–1,500 บาท/เดือน

Plan B — Production

ใช้งานระยะยาว ประมาณการค่า API รวม 3,000–8,000 บาท/เดือน

7. ความเสี่ยงและแนวทางลด

ความเสี่ยง	ระดับ	แนวทาง
เสียงกับปากไม่ตรงกันเมื่อใช้งานนาน	สูง	ตรวจสอบตำแหน่งเสียงแบบ real-time แทนการนับเวลาตายตัว
ต้องมีอินเทอร์เน็ตตลอดเวลา	สูง	เตรียมเสียงบันทึกไว้ล่วงหน้าสำหรับคำตอบพื้นฐาน พร้อมแจ้งผู้ใช้เมื่อเน็ตหลุด
รูปปากภาษาไทยอาจไม่แม่นยำเท่าภาษาอังกฤษ	กลาง	ทดสอบก่อน — ถ้าไม่ผ่านให้ขยับปากตามความดังเสียงแทน
ระบบทำงานหนักขึ้นเมื่อเปิดทั้งวันนาน	กลาง	นำวิดีโอเดิมกลับมาใช้ซ้ำ ไม่สร้างใหม่ทุกครั้ง
รับเสียงผิดพลาดในสภาพแวดล้อมที่เสียงดัง	กลาง	Plan B ใช้ Whisper API ซึ่งแม่นยำกว่าในที่เสียงรบกวน
Kiosk ไม่ยอมเล่นวิดีโออัตโนมัติ	ต่ำ	ตั้งค่า Electron ให้อนุญาตการเล่นอัตโนมัติ

8. การทดสอบความเป็นไปได้ (POC) — 2–3 วันก่อนเริ่มโครงการ

3 สิ่งที่ต้องทดสอบก่อนยืนยัน scope

- 1 คุณภาพรูปปากภาษาไทย — ทดสอบว่า Azure TTS ส่งสัญญาณรูปปากภาษาไทยได้แม่นยำและตรงเวลาพอสำหรับการขยับปาก
- 2 การสลับคลิปปาก — ทดสอบความถี่ของการสลับคลิปบน hardware kiosk จริง
- 3 แผนสำรอง — ถ้าสัญญาณปากไม่ดีพอ ให้ขยับปากตามความดังเสียงแทน — ง่ายกว่าและไม่ต้องรอสัญญาณ

ราคาในใบเสนอราคาอ้างอิงจากวิธีการที่วางแผนไว้ข้างต้น หากผลการทดสอบพบว่าต้องปรับวิธีอย่างมีนัยสำคัญ ผู้รับจ้างจะแจ้งให้ทราบก่อนดำเนินการต่อ